



Центр непрерывного образования



Аналитик данных
программа профессиональной переподготовки



Определение перспективных локаций для банкоматов с применением ML (на примере Москвы)

Итоговый проект (НИУ ВШЭ, DA-10)

Гурский Антон Анатольевич

Руководитель: Паточенко Евгений

Ценность задачи

- Банкам важно выбирать точки с максимальной отдачей — высокий трафик и рентабельность.
- Инструмент ранжирует локации, снижает ошибки и ускоряет вывод банкоматов.
- Повышение удобства для клиентов: банкоматы в шаговой доступности.

Постановка задачи

- Цель: определить факторы и построить модель, предсказывающую перспективные точки.
- Что делаем: собираем геоданные (точки интереса, банкоматы), очищаем, формируем признаки, обучаем модели.
- Ответ: какие факторы сильнее всего влияют и где ставить банкоматы в первую очередь.

Данные и источники

- OpenStreetMap (OSM) – открытые картографические данные.
- Слои:
 - – банкоматы
 - – точек интереса (POI – кафе, магазины, аптеки, остановки)
 - – границы города.
- Сохранение сырых и обработанных слоёв для воспроизводимости (data/raw, data/processed).


Инструменты и библиотеки

- Python: pandas, GeoPandas, Shapely, OSMnx, matplotlib.
- ML: scikit-learn (Logistic Regression, Decision Tree, Random Forest), CatBoost.
- Шаги исследования:
- сбор → подготовка → признаки → модель.




Методология: подготовка геоданных

- Единая метрическая проекция (PSG:3857) — корректные расстояния и буферы.
- Очистка дубликатов и пустых геометрий, нормализация атрибутов.
- Контроль границ Москвы, визуальная проверка корректности выгрузок.



Распределение точек интереса

- После ограничения территории границами МКАД:
- Банкоматы: 2059 → **1790**
- Точки интереса (POI): 32 619 → **26 271**
- **Результат:**
- Остались только релевантные данные для анализа спроса и размещения банкоматов в пределах Москвы.



Сетка кандидатов и целевая переменная


- Регулярная сетка точек внутри МКАД — кандидаты для установки.
- Разметка:
 - реальные АТМ = 1 (14,2%)
 - кандидаты без АТМ = 0 (85,8%)

Итог:

датасет с признаками доступности и
Распределением классов.

	Тип	Количество
0	Кандидаты	10795
1	АТМ	1790
2	Итого	12585

Единый датасет (all_points): кандидаты и АТМ в пределах МКАД



Признаки (feature engineering)

- Радиусы доступности: 300 м и 500 м вокруг точки-кандидата.
- Плотность инфраструктуры: кафе, магазины, аптеки, остановки, рестораны.
- Суммарные показатели: POI

Признак	Максимум	Среднее (без АТМ)	Среднее (с АТМ)
POI, 500 м (все)	22	7,6	22
POI, 300 м (все)	58	2,8	10,5
Остановки, 500 м	31	2,6	5,1
Магазины, 500 м	22	1,9	4,5
Кафе, 500 м	61	1,3	5,5

Итоговый датасет


- Размер итогового датасета: **12 585 точек × 12 признаков**.
- В точках с банкоматами значения признаков выше в 2–3 раза.
- Это подтверждает зависимость размещения банкоматов от инфраструктуры.

Сводная таблица по ТОП-признакам

	Без банкомата	С банкоматом	Разница
poi_sum_500	15.198	43.968	28.769
poi_sum_300	5.492	20.917	15.426
cafe_500	1.311	5.539	4.228
restaurant_500	0.731	3.489	2.758
shop_500	1.867	4.542	2.675
bus_stop_500	2.572	5.108	2.536
cafe_300	0.486	2.693	2.207
pharmacy_500	1.118	3.306	2.188
shop_300	0.672	2.155	1.484
bus_stop_300	0.921	2.372	1.451
restaurant_300	0.264	1.606	1.341
pharmacy_300	0.403	1.633	1.230

Районы Москвы по плотности АТМ

- В центре города банкоматов значительно больше, чем на окраинах.
- Топ-районы: Замоскворечье, Тверской, Арбат (2,5–4,2 банкомата/км²).
- Анти-топ районы: Метрогородок, Алтуфьевский, Бескудниковский (0,05–0,13 банкомата/км²).
- Метро: Курская — лидер по доступности (23 банкомата в радиусе 300 м)



Построение и обучение ML-модели

- Убраны текстовые и служебные столбцы (element, operator, brand, id).
- Пропуски заменены нулями.
- Сформированы признаки (X) и целевая переменная ($y = \text{target}$).
- Проверен баланс классов: сильный дисбаланс учтён при моделировании.
- Данные разделены на train/test (70/30)

Модели для обучения

- Logistic Regression: Простая и интерпретируемая модель, задаёт базовый уровень качества.
- Decision Tree: Иерархическая модель, легко объяснять, но склонна к переобучению.
- Random Forest : Ансамбль деревьев, даёт более устойчивые результаты, лучше Precision.
- CatBoost : Градиентный бустинг, оптимизирован для категориальных и дисбалансных данных, показывает лучший Recall и ROC-AUC.

Метрики оценки качества моделей

- Accuracy – доля правильных предсказаний.
- Precision – насколько модель точна в положительных предсказаниях.
- Recall – насколько полно модель находит все положительные объекты.
- F1-score – баланс между Precision и Recall.
- ROC-AUC – способность модели различать классы на разных порогах.
- PR-AUC – качество модели при несбалансированных классах (Precision–Recall).

Матрица распределения признаков






- Сильнее всего с наличием банкомата связаны суммарные показатели POI: 300 м (0.50) и 500 м (0.46).
- Дополнительно заметный сигнал дают аптеки, кафе и магазины (0.36–0.38).
- Остановки и рестораны показывают более слабую, но стабильную зависимость.

Матрица корреляций признаков и target

cafe_300	1.00	0.61	0.38	0.36	0.23	0.88	0.62	0.39	0.38	0.24	0.78	0.72	0.37
restaurant_300	0.61	1.00	0.27	0.27	0.18	0.63	0.87	0.31	0.30	0.19	0.68	0.65	0.32
pharmacy_300	0.38	0.27	1.00	0.68	0.48	0.35	0.26	0.81	0.64	0.46	0.73	0.63	0.38
shop_300	0.36	0.27	0.68	1.00	0.45	0.34	0.25	0.64	0.80	0.46	0.74	0.63	0.37
bus_stop_300	0.23	0.18	0.48	0.45	1.00	0.22	0.17	0.46	0.45	0.76	0.63	0.52	0.33
cafe_500	0.88	0.63	0.35	0.34	0.22	1.00	0.72	0.43	0.42	0.26	0.73	0.82	0.36
restaurant_500	0.62	0.87	0.26	0.25	0.17	0.72	1.00	0.33	0.31	0.20	0.63	0.74	0.32
pharmacy_500	0.39	0.31	0.81	0.64	0.46	0.43	0.33	1.00	0.76	0.53	0.69	0.76	0.37
shop_500	0.38	0.30	0.64	0.80	0.45	0.42	0.31	0.76	1.00	0.54	0.69	0.77	0.36
bus_stop_500	0.24	0.19	0.46	0.46	0.76	0.26	0.20	0.53	0.54	1.00	0.57	0.64	0.32
poi_sum_300	0.78	0.68	0.73	0.74	0.63	0.73	0.63	0.69	0.69	0.57	1.00	0.89	0.50
poi_sum_500	0.72	0.65	0.63	0.63	0.52	0.82	0.74	0.76	0.77	0.64	0.89	1.00	0.46
target	0.37	0.32	0.38	0.37	0.33	0.36	0.32	0.37	0.36	0.32	0.50	0.46	1.00
cafe_300	restaurant_300	pharmacy_300	shop_300	bus_stop_300	cafe_500	restaurant_500	pharmacy_500	shop_500	bus_stop_500	poi_sum_300	poi_sum_500	target	

Влияние признаков на модели



- Logistic Regression — учитывает широкий спектр признаков. Лидеры: POI (300 м), аптеки (300 м), остановки (500 м). Хорошо отражает роль инфраструктуры, но даёт много ложных срабатываний.
- Decision Tree — фокусируется почти полностью на одном признаке: POI (300 м). Простая интерпретация, но ограниченные возможности.
- Random Forest — распределяет влияние признаков более сбалансированно: POI (300/500 м), кафе, остановки, аптеки. Даёт наибольшую точность (Precision), но снижает полноту (Recall).



CatBoost

- Accuracy = 0.80, Recall = 0.75, Precision = 0.40, F1 = 0.52.
- Лучший ROC-AUC = 0.87, PR-AUC = 0.54.
- Баланс Precision–Recall достигается при пороге 0.5–0.6: модель охватывает большинство банкоматов при приемлемом уровне ложных срабатываний.
- Важность признаков:
- Наибольший вклад — суммарные POI в 300 м (~33%).
- Важны и более широкие зоны: POI в 500 м, остановки и магазины.


Модель учитывает и ближайшее окружение, и более широкую инфраструктурную насыщенность



Результаты моделирования метрики

Сравнение четырёх моделей на
отложенной выборке:

- **CatBoost** — лучший Recall (0.75) и максимальный ROC-AUC (0.87)
- **Random Forest** — лучшая Accuracy (0.88), Precision (0.61) и PR-AUC (0.56)



Модель	Accuracy	Precision	Recall	F1	ROC-AUC	PR-AUC
Logistic Regression	0.80	0.40	0.72	0.51	0.86	0.52
Decision Tree	0.76	0.35	0.79	0.49	0.84	0.45
Random Forest	0.88	0.61	0.41	0.49	0.83	0.56
CatBoost	0.80	0.40	0.75	0.52	0.87	0.54

ML: ВЫВОДЫ

Протестированы 4 модели:

- **Logistic Regression** — сбалансированная, но с низкой точностью.
- **Decision Tree** — простая, повышает Recall, но менее устойчива.
- **Random Forest** — лучшая точность и Accuracy, но низкий Recall.
- **CatBoost** — лучший Recall и ROC-AUC, хорошо находит перспективные точки.


Выбор модели зависит от приоритета:

- интерпретация — Logistic Regression / Decision Tree;
- высокая точность — Random Forest;
- максимальный охват — CatBoost.

Итог: насыщенность инфраструктурой (POI, аптеки, магазины, остановки) — ключевой фактор размещения банкоматов.

Визуализации и аналитика

- На карте Москвы показаны предсказанные вероятности наличия банкомата (CatBoost).
- Тёмные зоны соответствуют районам с высокой вероятностью — в основном центр и крупные транспортные узлы.
- Светлые зоны отражают низкую вероятность, то есть «пустые» или жилые районы.



Заключение

Подтверждена гипотеза

- Наличие банкоматов зависит от инфраструктуры.
- Лучшие признаки: Точки интереса суммарно, аптеки и кафе

Выбраны модели под бизнес-задачи

- CatBoost — максимальный охват
- Random Forest — высокая точность

Визуализация:

Тёмные зоны (центр, транспортные узлы) — лидеры.

Светлые зоны (окраины) — потенциал для пилотов.

Дальнейшие шаги

- Новые данные: пассажиропоток, население
- Интерактивный дашборд
- Развитие ML-модели (XGBoost, LightGBM)
- Дообучение на новых данных



Спасибо за
внимание!
